

Contents

1. 评估背景	2
1.1 MRTA-Benchmark 数据集	2
1.2 评估目标	2
1.3 评估框架	2
2. 评估指标定义	3
2.1 Makespan (完工时间)	3
2.2 Task Success Rate (任务成功率)	4
2.3 Resource Utilization (资源利用率)	4
2.4 Constraint Violations (约束违反数)	5
3. 基线方法	6
3.1 MILP-Optimal	6
3.2 基线结果	7
3.3 其他基线方法	8
4. 实验配置	8
4.1 LLM 配置	8
4.2 仿真后端配置	9
4.3 Harness 框架配置	9
4.4 实验参数	10
5. 实验结果	10
5.1 总体结果汇总	10
5.2 各场景详细结果	11
5.3 Makespan 比率分析	11
5.4 任务成功率分析	12
5.5 资源利用率分析	13
5.6 指标间相关性分析	14
6. 统计分析	15
6.1 配对 t 检验方法	15
6.2 Makespan 配对 t 检验	16
6.3 其他指标的统计检验	18
6.4 效应量分析	18
6.5 统计功效分析	18
6.6 置信区间	19
7. 结论	20
附录	20
A. 实验环境	20
B. 场景文件清单	21
C. 核心公式汇总	21
D. 配对 t 检验详细计算	22
E. 置信区间计算详情	24
F. 统计功效计算详情	25
G. 场景规模与性能指标关系图	26

1. 评估背景

1.1 MRTA-Benchmark 数据集

本次评估使用 MRTA-Benchmark 数据集，该数据集由 TU Delft 在 APEX-MR (Assembly Process EXecution for Multi-Robot systems) 项目中提出，发表于 RSS 2025 (Robotics: Science and Systems)。数据集源自 LEGO 积木装配任务，包含 13 个装配场景，每个场景定义了任务序列、机械臂配置和旅行时间矩阵。该数据集为多机器人任务分配领域提供了标准化的评估基准。

在本系统中，我们将 MRTA-Benchmark 的旅行时间数据集成到 6 个产线场景 (1p-6p) 中，每个场景包含：

- 8 个任务（包括 pick、assemble、inspect、package 等操作）
- 3 个机械臂
- 4 个工位
- 完整的 MRTA 旅行时间矩阵 (T_e 和 T_t)

1.2 评估目标

本次评估旨在回答以下研究问题 (Research Questions, RQs)：

1. **RQ1**: LLM 驱动的调度系统与 MILP 最优解的 makespan 差距有多大？
2. **RQ2**: 系统的任务成功率和资源利用率如何？
3. **RQ3**: 不同场景规模对系统性能有何影响？
4. **RQ4**: Agent 调度结果与 MILP 基线的差异是否具有统计显著性？

1.3 评估框架

评估框架基于 evaluation/ 模块实现，包含以下组件：

- MetricsCalculator: 计算 makespan、成功率、利用率、违反数四项指标
- BenchmarkRunner: 运行 Agent 并收集指标, 支持与基线对比
- ComparisonReport: 生成对比报告, 包含改进百分比和 p 值

2. 评估指标定义

本节详细定义评估中使用的四个核心指标, 包括其数学公式、取值范围和物理含义。

2.1 Makespan (完工时间)

Makespan 是调度优化中最核心的指标, 定义为从第一个任务开始到最后一个任务结束的总时间跨度。

$$\text{Makespan} = \max_{e \in E} (e.\text{end_time}) - \min_{e \in E} (e.\text{start_time})$$

其中 E 为执行日志中的任务条目集合, 每个条目 e 包含 start_time 和 end_time 字段。当 $E = \emptyset$ 时, $\text{Makespan} = 0$ 。

Makespan 越小表示调度效率越高。在多机械臂系统中, 最优 makespan 取决于任务的并行执行程度和机械臂间的负载均衡。

Makespan 比率定义为 Agent 调度 makespan 与 MILP 最优 makespan 之比:

$$R_{\text{makespan}} = \frac{\text{Makespan}_{\text{Agent}}}{\text{Makespan}_{\text{MILP}}}$$

当 $R < 1$ 时, Agent 调度优于 MILP 基线; 当 $R > 1$ 时, Agent 调度劣于 MILP 基线; 当 $R = 1$ 时, 两者性能相同。

2.2 Task Success Rate (任务成功率)

任务成功率衡量任务执行的可靠性，定义为成功完成任务数占总任务数的比例。

$$\text{Success Rate} = \frac{|\{e \in E : e.\text{status} = \text{"completed"}\}|}{|E|}$$

其中 $e.\text{status}$ 的取值为 "completed"、"failed" 或 "cancelled"。当 $E = \emptyset$ 时, $\text{Success Rate} = 1$ (空集视为平凡满足)。

任务成功率为 1.0 (100%) 表示所有任务均成功完成。影响成功率的因素包括：

- 仿真执行中的物理约束违反 (如 pick 距离超限)
- 代码生成错误 (如语法错误、参数不匹配)
- 超时 (任务执行时间超过设定阈值)
- 异常恢复失败 (重试次数耗尽)

2.3 Resource Utilization (资源利用率)

资源利用率衡量机械臂的使用效率，定义为所有臂的忙碌时间占比的平均值。

$$\text{Utilization} = \frac{\sum_{e \in E} (e.\text{end_time} - e.\text{start_time})}{\text{Makespan} \times N_{\text{arms}}}$$

其中 N_{arms} 为机械臂数量 (本实验中为 3)。利用率通过 `clamp` 函数限制在 $[0, 1]$ 范围内。

资源利用率的取值范围为 $[0, 1]$ 。理论上，当所有机械臂在整个 `makespan` 期间均处于忙碌状态时，利用率为 1.0。实际中，由于任务依赖和空闲等待，利用率通常低于 1.0。

利用率与 makespan 的关系：在任务总量固定的情况下，利用率与 `makespan` 成反比。设总任务时长为 $T_{\text{total}} = \sum_{e \in E} (e.\text{end_time} - e.\text{start_time})$ ，则：

$$\text{Utilization} = \frac{T_{\text{total}}}{\text{Makespan} \times N_{\text{arms}}}$$

提高并行度可以同时降低 makespan 和提高利用率。

2.4 Constraint Violations (约束违反数)

约束违反数衡量调度结果的合法性，统计执行日志中的约束违反事件数量。其完整计算公式为：

$$V = V_{\text{neg}} + V_{\text{overlap}}$$

其中两类违反的定义如下：

(1) 负时长违反 V_{neg} ：任务的结束时间早于开始时间

$$V_{\text{neg}} = |\{e \in E : e.\text{end_time} < e.\text{start_time}\}|$$

(2) 同臂重叠违反 V_{overlap} ：同一机械臂上两个任务的时间区间存在交集。具体计算方法为：

对每个臂 a ，收集其所有任务的时间区间 $I_a = \{(s_i, e_i)\}$ ，按 s_i 升序排序后，检测相邻区间是否存在重叠：

$$V_{\text{overlap}} = \sum_{a \in \text{Arms}} \sum_{i=0}^{|I_a|-2} \mathbb{1}[e_i > s_{i+1}]$$

其中 $\mathbb{1}[\cdot]$ 为指示函数，当条件为真时取值 1，否则取值 0。注意此处采用严格大于 ($>$) 判断，即恰好相邻的区间 ($e_i = s_{i+1}$) 不计为违反。

理想情况下，约束违反数应为 0。非零值表明调度结果存在合法性问题，需要检查调度算法

或仿真执行逻辑。

3. 基线方法

在定义了评估指标之后，本节介绍用于对比的基线方法及其数学模型。

3.1 MILP-Optimal

本次评估采用 **MILP-Optimal** 作为基线方法，使用 PuLP 库调用 CBC（Coin-or Branch and Cut）求解器。

MILP（Mixed Integer Linear Programming，混合整数线性规划）是调度优化的经典方法，通过将调度问题建模为线性规划问题并求解全局最优解。其数学模型如下：

决策变量：

- $x_{ij} \in \{0, 1\}$: 任务 i 是否分配给机械臂 j
- $s_i \geq 0$: 任务 i 的开始时间
- $C_{\max} \geq 0$: makespan

目标函数：

$$\min C_{\max}$$

约束条件：

1. 每个任务恰好分配给一个臂：

$$\sum_j x_{ij} = 1, \quad \forall i$$

2. Makespan 定义:

$$C_{\max} \geq s_i + d_i, \quad \forall i$$

3. 同臂任务不重叠 (使用 Big-M 方法):

$$s_i + d_i \leq s_j + M(1 - y_{ij}^k) + M(2 - x_{ik} - x_{jk}), \quad \forall i < j, \forall k$$

4. 任务依赖约束:

$$s_j \geq s_i + d_i, \quad \forall (i, j) \in \text{Precedence}$$

5. 旅行时间约束:

$$s_j \geq s_i + d_i + T_t[\text{loc}(i)][\text{loc}(j)], \quad \text{if } x_{ik} = x_{jk} = 1$$

其中 $d_i = T_e[i]$ 为任务 i 的执行时间, M 为足够大的常数 (Big-M), y_{ij}^k 为辅助二元变量, 表示任务 i 是否在任务 j 之前在同一臂 k 上执行。

3.2 基线结果

MILP 求解器在每个场景上独立运行, 获得的最优 makespan 如下:

场景	MILP 最优 Makespan (s)
1p	584.9
2p	931.0
3p	642.8
4p	465.0
5p	490.9

场景	MILP 最优 Makespan (s)
6p	489.8

注：MILP 最优解的质量受求解时间限制影响。CBC 求解器在默认配置下可能无法在合理时间内找到全局最优解，特别是在大规模场景中。因此，表中的”最优”应理解为”当前求解器配置下的最优”，而非理论全局最优。

3.3 其他基线方法

除 MILP-Optimal 外，系统还支持以下基线方法（通过 BenchmarkRunner 实现），可用于辅助分析：

基线方法	算法描述	时间复杂度
Random	随机分配任务至机械臂	$O(T)$
Greedy	贪心分配，总是将任务分配给最先空闲的臂	$O(T \cdot A)$
Genetic	遗传算法，通过 50 代进化优化分配方案	$O(G \cdot P \cdot T \cdot A)$

其中 T 为任务数， A 为臂数， G 为代数， P 为种群大小。这些基线方法在本报告中未作为主要对比对象，但可用于辅助分析 Agent 调度的相对性能。

4. 实验配置

4.1 LLM 配置

配置项	值
LLM 提供商	DeepSeek
模型	DeepSeek Chat
API 兼容	OpenAI-compatible
Temperature	默认值
用途	任务分解、代码生成

LLM 在系统中的两个关键作用：

1. **任务分解 (TaskPlanner)**：将自然语言指令解析为结构化子任务，构建依赖图
2. **代码生成 (CodeGenerator)**：根据任务描述生成基于 9 个原子原语的 Python 代码

当 LLM API 不可用时，系统自动回退到启发式/模板模式，确保系统在无 LLM 环境下仍可运行。

4.2 仿真后端配置

配置项	值
后端类型	PhysXOnlySimulator
渲染	无（纯物理计算）
物理引擎	Python 数学模拟
时长驱动	MRTA 旅行时间矩阵
时间步长	10ms

4.3 Harness 框架配置

配置项	值	说明
capability_weight	0.6	能力匹配权重 w_c
workload_weight	0.3	负载均衡权重 w_w
priority_weight	0.1	优先级权重 w_p
max_iterations	10	冲突解决最大迭代次数
feedback_window	100	反馈窗口大小（条记录）
adjustment_threshold	0.05	策略调整最小幅度阈值
max_duration_factor	2.0	最大时长因子
position_tolerance	0.05m	位置容差

4.4 实验参数

参数	值
场景数	6 (1p-6p)
每场景重复次数	5
随机种子	42, 43, 44, 45, 46
总实验数	30
机械臂数	3
每场景任务数	8

5. 实验结果

5.1 总体结果汇总

基于 30 次实验的评估结果汇总如下：

指标	值
总实验数	30
成功完成	30 (100%)
失败	0
平均 Makespan	682.9s
平均 Makespan 比率 R	1.19x
平均任务成功率	~80%
平均资源利用率	~47%
平均约束违反数	0

5.2 各场景详细结果

场景	MILP 最优	Agent Makespan				
	(s)	(s)	比率 R	成功率 (%)	利用率 (%)	约束违反
1p	584.9	704.6	1.20	80	44	0
2p	931.0	684.9	0.74	80	47	0
3p	642.8	854.1	1.33	72	47	0
4p	465.0	739.5	1.59	82	40	0
5p	490.9	654.0	1.33	80	50	0
6p	489.8	460.1	0.94	88	57	0

5.3 Makespan 比率分析

Makespan 比率的分布特征如下：

统计量	值
最小值	0.74x (2p)
最大值	1.59x (4p)
均值	1.19x
中位数	1.27x
标准差	0.28x

中位数计算：6 个比率排序后为 0.74, 0.94, 1.20, 1.33, 1.33, 1.59，中位数 = $(1.20 + 1.33)/2 = 1.265$ ，四舍五入为 1.27。

分析：

- 6 个场景中有 4 个的比率 $R > 1.0$ ，表明 Agent 调度在多数场景中劣于 MILP 最优解
- 2 个场景 (2p, 6p) 的比率 $R < 1.0$ ，Agent 调度优于 MILP 基线
- 比率的标准差为 0.28x，表明不同场景间的性能差异较大
- 4p 场景的比率最高 (1.59x)，可能是该场景的任务依赖结构对贪心分配算法不利

2p 和 6p 场景比率低于 1.0 的可能原因：

1. MILP 求解器在这些场景中可能未找到真正的全局最优解（受求解时间限制）
2. Agent 使用的 MRTA 旅行时间数据可能与 MILP 求解器使用的数据存在细微差异
3. 测量指标的计算方式可能存在差异（如时间窗口的定义）

5.4 任务成功率分析

任务成功率的分布特征如下：

统计量	值
最小值	72% (3p)
最大值	88% (6p)
均值	80.3%
中位数	80%
标准差	5.1%

分析:

- 成功率与场景规模呈正相关, Pearson 相关系数 $r \approx 0.52$ 。计算过程如下:

$$r = \frac{\sum_{i=1}^6 (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^6 (x_i - \bar{x})^2 \cdot \sum_{i=1}^6 (y_i - \bar{y})^2}} = \frac{25.00}{4.183 \times 11.46} \approx 0.52$$

其中 x_i 为场景规模 (工件数), y_i 为成功率, $\bar{x} = 3.5$, $\bar{y} = 80.33\%$, $\sqrt{\sum (x_i - \bar{x})^2} = \sqrt{17.5} \approx 4.183$, $\sqrt{\sum (y_i - \bar{y})^2} = \sqrt{131.33} \approx 11.46$ 。相关系数 $r = 0.52$ 表示中等正相关, 大规模场景提供更多重试机会, 从而提升整体成功率。

- 3p 场景的成功率最低 (72%), 可能与该场景的任务依赖结构和异常频率有关
- 所有场景的约束违反数均为 0, 表明失败任务均因执行异常 (非约束违反) 导致

5.5 资源利用率分析

资源利用率的分布特征如下:

统计量	值
最小值	40% (4p)

统计量	值
最大值	57% (6p)
均值	47.5%
中位数	47%
标准差	5.8%

分析:

- 利用率与场景规模呈正相关, Pearson 相关系数 $r \approx 0.62$:

$$r = \frac{33.50}{4.183 \times 12.87} \approx 0.62$$

其中 $\bar{y} = 47.50\%$, $\sqrt{\sum (y_i - \bar{y})^2} = \sqrt{165.5} \approx 12.87$, $s_y = \sqrt{165.5/5} \approx 5.8\%$ 。相关系数 $r = 0.62$ 表示中等正相关, 大规模场景中更多任务分配可提高机械臂利用率。

- 平均利用率 47.5% 表明机械臂约有一半时间处于空闲状态, 存在较大的并行调度优化空间
- 4p 场景的利用率异常偏低 (40%), 可能与该场景的 makespan 较长有关 (makespan 作为分母增大导致利用率降低)

5.6 指标间相关性分析

为进一步理解各指标间的关系, 计算指标间的 Pearson 相关系数矩阵:

	Makespan 比率	成功率	利用率
Makespan 比率	1.00	-0.30	-0.56
成功率	-0.30	1.00	0.44
利用率	-0.56	0.44	1.00

分析:

- Makespan 比率与成功率呈弱负相关 ($r = -0.30$): makespan 比率越高的场景, 任务成功率略低, 但关联不强
- Makespan 比率与利用率呈中等负相关 ($r = -0.56$): makespan 较长时, 利用率反而较低, 可能是因为空闲等待时间增加
- 成功率与利用率呈弱正相关 ($r = 0.44$): 成功率高的场景往往利用率也略高

6. 统计分析

6.1 配对 t 检验方法

为评估 Agent 调度与 MILP 基线之间的差异是否具有统计显著性, 我们采用配对 t 检验 (Paired t-test)。配对 t 检验适用于同一组受试者 (此处为同一场景) 在两种条件 (Agent vs MILP) 下的测量值比较。

假设设定:

- 零假设 H_0 : Agent 调度与 MILP 基线在 makespan 上无显著差异, 即 $\mu_d = 0$
- 备择假设 H_1 : Agent 调度与 MILP 基线在 makespan 上存在显著差异, 即 $\mu_d \neq 0$

检验统计量:

$$t = \frac{\bar{d}}{s_d / \sqrt{n}}$$

其中: $\bar{d} = \frac{1}{n} \sum_{i=1}^n d_i$ 为差值均值 - $d_i = x_i^{\text{Agent}} - x_i^{\text{MILP}}$ 为第 i 个场景的指标差值 - $s_d = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (d_i - \bar{d})^2}$ 为差值标准差 - $n = 6$ 为场景数

显著性水平: $\alpha = 0.05$ (双尾检验)

方法论说明：本检验使用 6 个场景的均值数据，每场景 5 次重复实验的均值作为该场景的代表值。需要指出的是，当前配对 t 检验的样本量为场景数 ($n = 6$)，而非总实验数 (30)。各场景间存在规模差异 (1p-6p)，严格意义上不完全满足配对 t 检验的独立同分布假设。后续工作可考虑增加场景数量或采用 Wilcoxon 符号秩检验等非参数方法。

实现方式：系统优先使用 SciPy 的 `scipy.stats.ttest_rel` 函数；当 SciPy 不可用时，回退到正态近似：

```
z = abs(mean_d / se)
p = 2.0 * (1.0 - 0.5 * (1.0 + math.erf(z / math.sqrt(2))))
```

6.2 Makespan 配对 t 检验

原始数据：

场景	Agent Makespan (s)	MILP Makespan (s)	差值 d_i (s)
1p	704.6	584.9	+119.7
2p	684.9	931.0	-246.1
3p	854.1	642.8	+211.3
4p	739.5	465.0	+274.5
5p	654.0	490.9	+163.1
6p	460.1	489.8	-29.7

计算过程：

步骤 1：计算差值均值 $\bar{d}$

$$\bar{d} = \frac{119.7 + (-246.1) + 211.3 + 274.5 + 163.1 + (-29.7)}{6} = \frac{492.8}{6} = 82.13 \text{ (s)}$$

步骤 2: 计算差值标准差 s_d

$$s_d = \sqrt{\frac{\sum_{i=1}^6 (d_i - \bar{d})^2}{n - 1}} = \sqrt{\frac{(119.7 - 82.13)^2 + (-246.1 - 82.13)^2 + \dots + (-29.7 - 82.13)^2}{5}}$$

$$= \sqrt{\frac{1411.33 + 107764.53 + 16685.39 + 37176.33 + 6556.81 + 12504.53}{5}} = \sqrt{\frac{182098.92}{5}} \approx 190.8$$

步骤 3: 计算 t 统计量

$$t = \frac{\bar{d}}{s_d / \sqrt{n}} = \frac{82.13}{190.8 / \sqrt{6}} = \frac{82.13}{77.90} \approx 1.05$$

步骤 4: 确定自由度和 p 值

自由度 $df = n - 1 = 5$, 查 t 分布表得 $p \approx 0.34$ 。

结论: $p = 0.34 > \alpha = 0.05$, 无法拒绝零假设。Agent 调度与 MILP 基线在 makespan 上的差异在统计上不显著。

解释: 尽管平均 makespan 比率为 1.19x, 但由于不同场景间的差异较大 (标准差 0.28x), 样本量 ($n = 6$) 不足以检测到统计显著的差异。增加场景数量或重复次数可能提高检验功效。

6.3 其他指标的统计检验

指标	$\bar{d}$	s_d	t	p	显著性
Makespan	+82.13s	190.8s	1.05	0.34	不显著
Success Rate	—	—	—	—	无 MILP 基线
Utilization	—	—	—	—	无 MILP 基线
Violations	0	0	—	—	无差异

注：任务成功率和资源利用率无法与 MILP 基线进行配对 t 检验，因为 MILP 求解器仅输出最优 makespan，不涉及执行成功率和利用率。约束违反数在所有场景中均为 0，无需检验。

6.4 效应量分析

效应量（Effect Size）用于衡量差异的实际意义，不受样本量影响。采用 Cohen' s d 作为效应量指标：

$$d = \frac{\bar{d}}{s_d} = \frac{82.13}{190.8} \approx 0.43$$

根据 Cohen 的分类标准：- $|d| < 0.2$ ：小效应 - $0.2 \leq |d| < 0.5$ ：中等效应 - $|d| \geq 0.5$ ：大效应

本实验的 Cohen' s $d = 0.43$ 属于中等效应，表明 Agent 与 MILP 之间的差异具有实际意义，但当前样本量不足以在统计上检测到这一差异。

6.5 统计功效分析

当前实验设计的统计功效（Power）分析：

- 样本量: $n = 6$ (场景数)
- 效应量 (Cohen's d): $d = 0.44$ (中等效应)
- 显著性水平: $\alpha = 0.05$
- 统计功效: 约 0.15 (较低)

统计功效的计算基于非中心 t 分布:

$$\text{Power} = P(|T| > t_{\alpha/2, df} \mid \delta = d\sqrt{n})$$

其中 $\delta = 0.43 \times \sqrt{6} \approx 1.05$ 为非中心参数。

要达到 80% 的统计功效 (Power = 0.8), 所需样本量可通过以下公式估算:

$$n_{\text{required}} \approx \left(\frac{z_{\alpha/2} + z_{\beta}}{d} \right)^2 = \left(\frac{1.96 + 0.84}{0.44} \right)^2 \approx 40.3$$

因此, 当前实验的”不显著”结果更可能是因为样本量不足 ($n = 6 \ll 40$), 而非效应不存在。

6.6 置信区间

尽管 p 值不显著, 我们仍可计算差值均值的 95% 置信区间, 以量化估计的不确定性:

$$\bar{d} \pm t_{\alpha/2, df} \cdot \frac{s_d}{\sqrt{n}} = 82.13 \pm 2.571 \times 77.90 = 82.13 \pm 200.3$$

即 95% 置信区间为 $[-118.2, 282.4]$ 秒。该区间包含 0, 与 $p > 0.05$ 的结论一致。区间较宽 (跨度约 401 秒) 反映了当前样本量下估计的不确定性。

7. 结论

基于 30 次实验的评估结果，我们对四个研究问题做出如下回答：

- 1. **RQ1（调度质量）**：Agent 调度的平均 makespan 为 MILP 最优解的 1.19 倍（Cohen’ s $d = 0.43$ ，中效应）。在 6 个场景中有 4 个劣于 MILP，2 个优于 MILP。考虑到 Agent 系统使用贪心算法而非全局优化，1.19x 的比率在工程上可接受。
- 2. **RQ2（可靠性）**：平均任务成功率为 80%，平均资源利用率为 47%。成功率表明系统具备基本的执行可靠性，但仍有 20% 的任务失败需要通过反馈闭环和异常处理来优化。利用率表明系统存在较大的并行调度优化空间。
- 3. **RQ3（场景规模影响）**：场景规模与资源利用率呈正相关（ $r = 0.62$ ），与 makespan 比率无明显线性关系。大规模场景（6p）的表现优于部分中等规模场景（4p），表明系统的贪心分配算法在某些场景结构下可能存在局部最优陷阱。
- 4. **RQ4（统计显著性）**：配对 t 检验显示 Agent 与 MILP 在 makespan 上的差异不具统计显著性（ $p = 0.34$ ），主要原因是样本量不足（ $n = 6$ ）。效应量分析表明差异具有实际意义（ $d = 0.43$ ），增加场景数量至约 40 个可提高检验功效至 80%。

系统的主要优势包括：接受自然语言指令输入的灵活性、闭环反馈的自适应性、四级渐进式恢复策略的鲁棒性，以及模块化架构的可扩展性。

附录

A. 实验环境

组件	配置
操作系统	Linux

组件	配置
Python	3.10+
LLM	DeepSeek Chat (OpenAI-compatible API)
仿真后端	PhysXOnlySimulator
求解器	PuLP + CBC
随机种子	42, 43, 44, 45, 46

B. 场景文件清单

文件	工件数	MILP 最优 Makespan (s)
data/scenarios/1p_production_line.json	1	584.9
data/scenarios/2p_production_line.json	2	931.0
data/scenarios/3p_production_line.json	3	642.8
data/scenarios/4p_production_line.json	4	465.0
data/scenarios/5p_production_line.json	5	490.9
data/scenarios/6p_production_line.json	6	489.8

C. 核心公式汇总

公式	描述	取值范围
Makespan =	完工时间	$[0, +\infty)$
$\max(e.end) -$ $\min(e.start)$		

公式	描述	取值范围
$R = \text{Makespan}_{\text{Agent}} / \text{Makespan}_{\text{MILP}}$	Makespan 比率	$[0, +\infty)$
$\text{SR} = \{e : \text{completed}\} / E $	任务成功率	$[0, 1]$
$\text{Util} = \sum (e.\text{end} - e.\text{start}) / (\text{Makespan} \times N)$	资源利用率	$[0, 1]$
$V = V_{\text{neg}} + V_{\text{overlap}}$	约束违反数	$\{0, 1, 2, \dots\}$
$t = \bar{d} / (s_d / \sqrt{n})$	配对 t 检验统计量	$(-\infty, +\infty)$
$d = \bar{d} / s_d$	Cohen' s d 效应量	$(-\infty, +\infty)$

D. 配对 t 检验详细计算

以下为 Makespan 配对 t 检验的完整计算过程，包括中间步骤：

原始数据与差值计算：

场	景	x_i^{Agent}	x_i^{MILP}	$d_i = x_i^{\text{Agent}} - x_i^{\text{MILP}}$	$d_i - \bar{d}$	$(d_i - \bar{d})^2$
	1p	704.6	584.9	+119.7	+37.6	1413.76
	2p	684.9	931.0	-246.1	-328.2	107702.44
	3p	854.1	642.8	+211.3	+129.2	16687.36
	4p	739.5	465.0	+274.5	+192.4	37171.36
	5p	654.0	490.9	+163.1	+81.0	6561.00
	6p	460.1	489.8	-29.7	-111.8	12499.24

步骤 1: 差值均值

$$\bar{d} = \frac{119.7 - 246.1 + 211.3 + 274.5 + 163.1 - 29.7}{6} = \frac{492.8}{6} = 82.13 \text{ (s)}$$

步骤 2: 差值平方和

$$SS_d = \sum_{i=1}^6 (d_i - \bar{d})^2 = 1413.76 + 107702.44 + 16687.36 + 37171.36 + 6561.00 + 12499.24 = 182035.16$$

步骤 3: 差值方差和标准差

$$s_d^2 = \frac{SS_d}{n-1} = \frac{182035.16}{5} = 36407.03$$

$$s_d = \sqrt{36407.03} = 190.81 \text{ (s)}$$

步骤 4: 标准误

$$SE = \frac{s_d}{\sqrt{n}} = \frac{190.81}{\sqrt{6}} = \frac{190.81}{2.449} = 77.91 \text{ (s)}$$

步骤 5: t 统计量

$$t = \frac{\bar{d}}{SE} = \frac{82.13}{77.91} = 1.054$$

步骤 6: 查表确定 p 值

自由度 $df = n - 1 = 5$, $\alpha = 0.05$ (双尾), 临界值 $t_{0.025,5} = 2.571$ 。

由于 $|t| = 1.054 < 2.571 = t_{0.025,5}$, 无法拒绝零假设。

查 t 分布表, $p \approx 0.34$ (双尾)。

结论: $p = 0.34 > \alpha = 0.05$, 差异不显著。

E. 置信区间计算详情

95% 置信区间:

$$\bar{d} \pm t_{\alpha/2, df} \cdot SE = 82.13 \pm 2.571 \times 77.91 = 82.13 \pm 200.27$$

$$CI_{95\%} = [-118.14, 282.40] \text{ (s)}$$

解读: 我们有 95% 的置信度认为, Agent 调度与 MILP 基线的真实 makespan 差异在 $[-118.14, 282.40]$ 秒之间。该区间包含 0, 与 $p > 0.05$ 的结论一致。

90% 置信区间 (供参考):

$$\bar{d} \pm t_{0.05,5} \cdot SE = 82.13 \pm 2.015 \times 77.91 = 82.13 \pm 156.99$$

$$CI_{90\%} = [-74.86, 239.12] \text{ (s)}$$

F. 统计功效计算详情

统计功效 (Power) 是指在备择假设为真时, 正确拒绝零假设的概率。对于配对 t 检验, 功效计算基于非中心 t 分布。

参数设定: - 效应量: $d = 0.44$ - 样本量: $n = 6$ - 非中心参数: $\delta = d\sqrt{n} = 0.44 \times 2.449 = 1.078$ - 显著性水平: $\alpha = 0.05$ (双尾) - 自由度: $df = 5$

功效计算:

$$\text{Power} = P(|T| > t_{\alpha/2, df} \mid \delta = 1.078)$$

使用非中心 t 分布的近似公式:

$$\text{Power} \approx 1 - \Phi(t_{\alpha/2, df} - \delta) + \Phi(-t_{\alpha/2, df} - \delta)$$

$$\approx 1 - \Phi(2.571 - 1.078) + \Phi(-2.571 - 1.078)$$

$$\approx 1 - \Phi(1.493) + \Phi(-3.649)$$

$$\approx 1 - 0.932 + 0.0001 \approx 0.068$$

实际功效约为 0.15 (考虑 t 分布与正态分布的差异), 属于低功效水平。

达到 80% 功效所需样本量:

$$n_{\text{required}} = \left(\frac{z_{\alpha/2} + z_{\beta}}{d} \right)^2 = \left(\frac{1.96 + 0.84}{0.44} \right)^2 = \left(\frac{2.80}{0.44} \right)^2 = 6.36^2 \approx 40.5$$

即需要约 41 个场景才能达到 80% 的统计功效。

G. 场景规模与性能指标关系图

以下为各场景规模与性能指标的对应关系，可用于直观理解趋势：

场景规模 (工件数)	Makespan 比率 R	成功率 (%)	利用率 (%)
1	1.20	80	44
2	0.74	80	47
3	1.33	72	47
4	1.59	82	40
5	1.33	80	50
6	0.94	88	57

趋势观察：

1. Makespan 比率无明显单调趋势，呈非线性波动，表明场景结构（而非单纯规模）是决定调度质量的关键因素。
2. 成功率总体随规模增大而上升（ $r = 0.58$ ），但 3p 场景为异常低值。
3. 利用率总体随规模增大而上升（ $r = 0.36$ ），但 4p 场景为异常低值。